

Propuesta de solución basada en RAG para la estandarización de respuestas a los motivos de no pago

10 de septiembre de 2026

Elaborado a partir del corpus de 1.197 conversaciones de WhatsApp y de los resultados de la capa de extracción con IA (notebooks 00 y 01)

1. Resumen ejecutivo

La operación de cobranza analizada ya intenta estandarizar sus respuestas, pero lo hace por la vía menos flexible posible. El 39,8 % de los mensajes del corpus corresponde a 155 textos plantilla que se repiten en veinte o más conversaciones: avisos legales, validaciones de identidad, encuestas de cierre y fórmulas de guion. Esa estandarización cubre el trámite, no la negociación. En el momento en que el cliente explica por qué no ha pagado, la respuesta vuelve a depender del criterio individual del asesor, y ahí es donde aparece la dispersión que este documento propone corregir.

La evidencia del propio corpus sostiene el diagnóstico. Cuando un cliente declara desempleo, un asesor pregunta si tiene seguro de desempleo, otro le recita el bloque de condiciones de la negociación y un tercero le indica un monto a cancelar sin acusar recibo de la situación. Las tres respuestas provienen de la misma operación y del mismo mes. Ninguna es incorrecta en sentido estricto; simplemente no son la misma política aplicada de forma consistente.

Se propone un sistema de generación aumentada por recuperación (RAG) que opere como copiloto del asesor humano: ante un motivo de no pago detectado en la conversación, el sistema recupera de una base de conocimiento controlada las políticas aplicables, los guiones aprobados y los antecedentes de respuestas que funcionaron, y sugiere al asesor una respuesta trazable, con su fuente citada y acotada a lo que la política permite ofrecer. El asesor decide si la usa, la edita o la descarta.

El documento describe la metodología por fases, los componentes de la arquitectura, un esquema de evaluación en cuatro niveles con criterios de aceptación explícitos, y un conjunto de metodologías analíticas complementarias para las preguntas que el RAG no resuelve por sí solo. Se declaran también las limitaciones conocidas del dataset, que condicionan tanto el alcance del prototipo como lo que legítimamente puede medirse sobre él.

2. Delimitación del problema

2.1 Desambiguación del enunciado

El reto pide «estandarizar las respuestas generadas a los clientes de los motivos de no pago». La formulación admite dos lecturas que conducen a sistemas distintos: un asistente que sugiere la respuesta al asesor humano, o un agente que responde directamente al cliente. La elección

no es cosmética, porque cambia el perfil de riesgo, los requisitos de latencia y la carga regulatoria.

Esta propuesta adopta la primera lectura, un copiloto con intervención humana obligatoria antes de cada envío, por cuatro razones documentadas en los datos. Primero, el corpus es sintético y no existe garantía de que sus patrones reproduzcan la operación real; automatizar sobre esa base sería construir política sobre un supuesto no verificado. Segundo, la operación es de cobranza, actividad sujeta a habeas data y a las reglas de trato al consumidor financiero, donde una promesa mal generada compromete a la entidad. Tercero, el corpus no contiene el manual de políticas: el sistema recuperaría de un corpus incompleto y necesita un revisor que detecte los huecos. Cuarto, y más concreto, el corpus muestra ya el costo de automatizar sin supervisión: en cuatro de las conversaciones peor evaluadas el bot cierra o interrumpe una conversación humana activa, dispara encuestas de satisfacción sobre un reclamo sin resolver y fuerza al cliente a repetir sus datos.

La arquitectura propuesta no impide una evolución posterior hacia respuesta directa en intenciones de bajo riesgo, como consultas de saldo o canales de pago. Se plantea como una fase posterior condicionada a resultados, no como el punto de partida.

2.2 Qué se estandariza y qué no

Estandarizar no significa uniformar el texto. Significa garantizar que ante el mismo motivo, el mismo producto y el mismo tramo de mora, dos asesores ofrezcan las mismas alternativas, con las mismas condiciones y las mismas advertencias. El tono y la adaptación al caso siguen siendo del asesor. Lo que el sistema fija es el contenido sustantivo de la oferta y su respaldo documental.

3. Evidencia que sustenta la propuesta

El diseño parte de mediciones sobre el corpus, no de supuestos genéricos sobre operaciones de cobranza. Las cifras relevantes se resumen a continuación.

Tabla 1. Evidencia del corpus relevante para el diseño del sistema

Hallazgo	Magnitud	Implicación de diseño
Mensajes plantilla (155 textos en 20+ conversaciones)	39,8 % del corpus	La estandarización actual existe pero cubre el trámite, no la negociación

Hallazgo	Magnitud	Implicación de diseño
Conversaciones con motivo de no pago respaldado por cita del cliente	439 de 1.197 (36,7 %)	El motivo es detectable automáticamente en poco más de un tercio de los casos
Mención de centrales de riesgo por el asesor	281 mensajes en 229 conversaciones	El argumento dominante ya está en uso y debe quedar acotado por política
Bloque «Condiciones de la negociación» citado por asesores	154 apariciones en 123 conversaciones	Existe un texto de política que circula sin documento fuente indexable
Acuerdos de pago verificados según la definición del enunciado	78 de 1.197 (cota superior del 6,5 %)	La base de «respuestas que funcionaron» es demasiado pequeña para sostener el corpus por sí sola
Conversaciones que repiten un mismo mensaje tres o más veces	249 (20,8 %)	La fricción del canal automatizado es un problema medible y separable del contenido

Fuente: elaboración propia sobre el corpus limpio de 42.005 mensajes y la salida de la capa de extracción con IA (modelo gpt-4o-mini, corrida del 10 de septiembre de 2026).

Tres consecuencias se desprenden de esta tabla. La primera es que el problema de estandarización es real y localizable: la dispersión no está en los saludos ni en los avisos legales, sino en el tramo de la conversación que sigue a la declaración del motivo. La segunda es que el corpus aporta materia prima suficiente para construir la base de conocimiento por la vía de los antecedentes, aunque no suficiente por la vía de los casos exitosos, que son apenas decenas. La tercera es que una parte importante de la insatisfacción observada no se corrige con mejores respuestas, sino con reglas de enrutamiento del bot; conviene no atribuir al RAG un problema que no le corresponde.

4. Metodología propuesta

El trabajo se reparte en cinco fases, cada una con algo tangible al final. El orden no es caprichoso: afinar la búsqueda antes de tener claro qué se va a buscar es tiempo perdido, y medir la calidad de las respuestas sin un conjunto de referencia contra el cual compararlas es quedarse en la impresión personal de quien mira.

Fase 1. Construcción del corpus de conocimiento

El corpus se arma en tres capas de distinta autoridad. La capa normativa y de política es la que manda: manual de cobranza, árbol de alternativas por producto y tramo de mora, condiciones de negociación, tarifario y canales de pago, más la normativa aplicable. Ninguno de estos documentos existe en el dataset, de modo que en el prototipo se construyen como documentos sintéticos a partir de los fragmentos que los asesores citan literalmente en las conversaciones, y en producción deben ser aportados por la operación. La capa de guion recoge las formulaciones aprobadas para cada situación, reconstruidas a partir de las semiplantillas del asesor ya identificadas. La capa de antecedentes contiene pares de motivo declarado por el cliente y respuesta del asesor, extraídos del corpus por sondeo léxico, que aportan decenas de casos por motivo y no solo los 21 acuerdos verificados con motivo respaldado.

Cada documento se indexa con metadatos obligatorios: motivo aplicable, producto, tramo de mora, vigencia, nivel de autoridad y unidad responsable. Los metadatos no son decoración administrativa; son lo que permite filtrar antes de buscar y lo que hace posible retirar del índice una política vencida sin reconstruirlo entero.

Fase 2. Normalización e indexación

El corpus conversacional presenta dos particularidades que obligan a un preprocesamiento explícito. Está íntegramente en mayúsculas y con tildes irregulares, lo que degrada tanto la recuperación léxica como la calidad de los embeddings; se normaliza a minúsculas con restitución de tildes por diccionario antes de indexar, conservando el texto original para la visualización. Y contiene 20.334 marcadores de anonimización, de los cuales un subconjunto rompió palabras corrientes del español al sustituir por subcadena: el 71,5 % de las conversaciones contiene al menos un fragmento dañado, y el daño cae precisamente sobre expresiones temporales como «mañana», «semana» o el mes de julio. Se aplica un diccionario de reparación de los fragmentos conocidos antes de indexar, y se preserva el marcador intacto en cualquier cita que el sistema devuelva al usuario.

La segmentación sigue la estructura del documento, no un conteo fijo de caracteres: cada alternativa de negociación, con sus condiciones y su elegibilidad, constituye una unidad recuperable. Fragmentos de 300 a 500 tokens con solapamiento del 15 % funcionan como referencia inicial, sujeta a ajuste según los resultados de la fase 4.

Fase 3. Recuperación y generación

Se combina búsqueda densa por embeddings multilingües con búsqueda léxica BM25, ponderadas mediante fusión recíproca de rangos. La razón es concreta: los términos que distinguen una alternativa de otra en este dominio son nombres propios y cifras (libranza, PSE, mora superior a 30 días, tasa nominal anual), donde la coincidencia léxica exacta es más fiable que la similitud semántica; pero la consulta llega formulada en lenguaje del cliente, donde la similitud semántica es indispensable. Sobre los candidatos recuperados actúa un reordenador de tipo cross-encoder que ajusta la relevancia final antes de pasar al generador.

La generación se realiza con un modelo de lenguaje bajo tres restricciones: responder únicamente con base en los fragmentos recuperados, citar la fuente de cada afirmación sustantiva, y abstenerse cuando la evidencia recuperada no alcance un umbral de suficiencia. La abstención es una respuesta válida y deseable: en un dominio donde prometer un descuento inexistente tiene consecuencias contractuales, un sistema que reconoce no saber es preferible a uno que completa el hueco con plausibilidad.

Fase 4. Evaluación

Se construye un conjunto de referencia de entre 80 y 120 consultas reales extraídas del corpus, cada una anotada manualmente con los fragmentos que deberían recuperarse y con una respuesta de referencia validada por un experto de la operación. Sin este conjunto no hay evaluación posible, solo impresiones. El detalle de las métricas se desarrolla en la sección 6.

Fase 5. Despliegue supervisado y aprendizaje continuo

El sistema se despliega inicialmente sobre un subconjunto de asesores, con registro completo de cada sugerencia, de la acción del asesor (aceptar, editar, descartar) y del desenlace de la conversación. Ese registro es el activo más valioso de la fase: convierte el uso cotidiano en datos de entrenamiento y permite medir, por primera vez con evidencia, si la estandarización mejora los resultados. Las respuestas editadas por los asesores alimentan la revisión periódica del corpus de conocimiento.

5. Componentes de la arquitectura

Hay dos flujos que conviene no confundir. Uno prepara el conocimiento y se ejecuta de tanto en tanto, cada vez que la operación cambia una política o publica un guion nuevo. El otro atiende

al asesor mientras la conversación está viva y tiene que responder en segundos. Los componentes de cada uno se describen por separado.

Tabla 2. Componentes del flujo de indexación

Componente	Función	Implementación propuesta
Ingesta documental	Carga de políticas, guiones y normativa con sus metadatos	Cargadores por formato con validación de esquema de metadatos obligatorios
Normalizador	Restitución de mayúsculas, tildes y marcadores rotos	Diccionario de reparación derivado del EDA; el texto original se conserva
Segmentador	División en unidades recuperables coherentes	Segmentación estructural por alternativa; 300 a 500 tokens con solapamiento
Codificador de embeddings	Representación vectorial de cada fragmento	Modelo multilingüe; alternativa local sin costo mediante sentence-transformers
Índice vectorial y léxico	Almacenamiento y búsqueda	FAISS o pgvector para el índice denso; BM25 para el léxico
Registro de versiones	Trazabilidad de qué política estaba vigente en cada respuesta	Versionado con fecha de vigencia y responsable por documento

Tabla 3. Componentes del flujo de consulta

Componente	Función	Criterio de diseño
Clasificador de motivo	Detección del motivo de no pago en la conversación en curso	Reutiliza la taxonomía y los prompts de la capa de extracción ya construida
Constructor de consulta	Traducción del motivo y el contexto a una consulta enriquecida	Incorpora producto y tramo de mora como filtros de metadatos
Recuperador híbrido	Búsqueda densa y léxica con fusión de rangos	Ningún fragmento fuera del filtro de política puede entrar al contexto
Reordenador	Ajuste fino de la relevancia de los candidatos	Cross-encoder sobre los primeros 20 resultados
Generador con guardas	Redacción de la sugerencia con citas	Abstención obligatoria por debajo del umbral de suficiencia
Validador de política	Verificación determinista previa al envío	Bloquea cifras, plazos o beneficios no presentes en los fragmentos recuperados

Componente	Función	Criterio de diseño
Interfaz del asesor	Presentación de la sugerencia con su fuente	Aceptar, editar o descartar; el envío nunca es automático
Observabilidad	Registro de consultas, fragmentos, acciones y desenlaces	Base de la evaluación continua y de las auditorías

El validador de política merece una nota aparte porque es el componente que distingue un prototipo de un sistema utilizable en cobranza. No es un modelo: es una verificación determinista que extrae del texto generado toda cifra, plazo, tasa o beneficio y comprueba que aparezca en los fragmentos recuperados. Si una cifra no tiene respaldo, la sugerencia se bloquea. Este mismo patrón ya se aplicó con buen resultado en la capa de extracción, donde una verificación determinista de rol redujo los falsos acuerdos de pago a la mitad sin costo adicional de inferencia.

6. Criterios de evaluación

Un sistema de este tipo puede fallar en sitios muy distintos, y conviene no mezclarlos. Puede buscar mal y traer la política equivocada. Puede buscar bien y redactar una respuesta que no se parece a lo que encontró. Puede hacer las dos cosas bien y aun así prometerle al cliente algo que la entidad no autoriza. Y puede funcionar impecablemente en pruebas y no servir de nada porque ningún asesor lo usa. Por eso la evaluación se separa en cuatro niveles: los tres primeros se miden en laboratorio, contra el conjunto de referencia, antes de que el sistema toque una conversación real; el cuarto solo se puede medir con el sistema en uso.

6.1 Nivel 1: recuperación

Aquí solo interesa una cosa: ¿la política que hacía falta estaba entre lo que el sistema trajo? La redacción posterior da igual, porque si el fragmento correcto nunca llegó al contexto, no hay forma de que la respuesta salga bien. La métrica principal es `recall@5`, es decir, cuántas veces el documento aplicable aparece entre los cinco primeros. Se mira también el orden en que llegan, porque un fragmento correcto en quinta posición compite con cuatro distractores y tiende a diluirse.

6.2 Nivel 2: generación

Dado que el sistema recuperó lo correcto, queda por ver si la respuesta se ciñe a ello. Se revisan cuatro cosas. Que cada afirmación con peso pueda rastrearse hasta un fragmento

recuperado, que es la fidelidad. Que las citas apunten a donde dicen apuntar, porque una cita mal enlazada es peor que ninguna: da confianza sin merecerla. Que la respuesta no se quede a medias frente a lo que un experto habría contestado. Y que el sistema se abstenga cuando la evidencia no alcanza, en lugar de rellenar el hueco con algo plausible.

Las tres primeras se pueden evaluar automáticamente con un modelo actuando de juez, siempre que esa evaluación se calibre antes contra un puñado de casos revisados a mano. Un juez automático sin calibrar no mide nada, solo traslada el problema de confianza un nivel más arriba.

6.3 Nivel 3: seguridad y cumplimiento

Este nivel funciona distinto de los anteriores: no promedia, veta. Un solo incumplimiento basta para frenar el despliegue por muy buenos que sean los demás números. Lo que se revisa es que el sistema no ofrezca alternativas fuera de política, no exponga datos de terceros, no omita las advertencias que la alternativa obliga a dar (el reporte a centrales, las condiciones de la negociación) y no empuje al cliente más allá de lo razonable. Lo último no es una preocupación abstracta. En el corpus hay clientes con un día de mora que escriben que aquello les parece acoso, y sería un mal resultado que un sistema nuevo hiciera ese patrón más eficiente.

6.4 Nivel 4: negocio

Comparar el antes y el después no sirve: en cobranza cambian a la vez la cartera, la campaña y el mes, y cualquier mejora sería imposible de atribuir. Hace falta repartir asesores comparables entre un grupo que usa el sistema y otro que no, y dejar correr el periodo. Los indicadores a seguir son cuatro: cuántos clientes se comprometen a pagar con fecha, qué opinan de la atención según el NPS que la operación ya recoge al cierre, cuánto se parecen entre sí las alternativas que distintos asesores ofrecen ante el mismo motivo, y con qué frecuencia los asesores usan la sugerencia en lugar de descartarla. El tercero es el que mide de verdad si hubo estandarización; el cuarto avisa temprano si el sistema estorba más de lo que ayuda.

Tabla 4. Qué se le exige al sistema antes de considerarlo aceptable

Qué se quiere comprobar	Cómo se mide	Meta inicial
Que encuentre la política correcta	La política aplicable aparece entre los cinco primeros fragmentos recuperados (recall@5)	Nueve de cada diez consultas

Qué se quiere comprobar	Cómo se mide	Meta inicial
Que la ponga arriba y no enterrada	Calidad del orden de esos cinco resultados (nDCG@5)	0,80 sobre un máximo de 1
Que no afirme nada por su cuenta	Proporción de afirmaciones sustantivas verificables en los fragmentos citados	Noventa y cinco de cada cien
Que las citas sean las que dice ser	Correspondencia entre cada cita y el contenido que invoca	Noventa y cinco de cada cien
Que sepa callarse	Casos sin evidencia suficiente en los que el sistema se abstiene en vez de improvisar	Ochenta y cinco de cada cien
Que no invente condiciones económicas	Cifras, plazos, tasas o beneficios sin respaldo en los documentos recuperados	Cero. Es criterio de veto
Que efectivamente estandarice	Dispersión de las alternativas ofrecidas ante un mismo motivo	Menor que en el grupo de control
Que los asesores lo usen	Sugerencias aceptadas o editadas, frente a las descartadas	Seis de cada diez a los tres meses

Las metas son puntos de partida para discutir con la operación, no umbrales heredados de ninguna norma. La primera tanda de consultas anotadas dirá cuáles eran optimistas y cuáles se quedaron cortas.

Hay algo que ninguno de estos cuatro niveles puede medir, y vale la pena decirlo antes de que lo pregunten: si el cliente que prometió pagar acabó pagando. El dataset no trae esa información. Todo lo que se mide aquí se detiene en el compromiso declarado, que es un paso intermedio y no el resultado. Cualquier cifra de impacto sobre el recaudo sería, con estos datos, una extrapolación disfrazada de medición.

7. Otras metodologías analíticas propuestas

El RAG resuelve la estandarización, que era lo que pedía el enunciado, pero deja varias preguntas de negocio sin tocar. Entender por qué la gente no paga, saber qué argumento funciona mejor o predecir quién va a cumplir su compromiso son problemas de otra naturaleza y piden herramientas distintas. Van siete, ordenadas por lo que aportan frente a lo que cuestan.

1. Modelado de tópicos sobre los motivos no clasificados. El 63,3 % de las conversaciones queda sin motivo respaldado y un 1,8 % cae en la categoría residual. Aplicar BERTopic o agrupamiento sobre los embeddings de los mensajes del cliente permitiría descubrir motivos emergentes que la taxonomía cerrada no contempla, y retroalimentar el diseño de esa taxonomía en lugar de darla por definitiva.

2. Destilación a un clasificador supervisado. El prompt fijo representa el 89 % de los tokens de entrada de la capa actual, que consumió quince millones de tokens sobre el corpus completo. Usar las etiquetas del modelo generativo, una vez validadas contra anotación humana, para entrenar un clasificador ligero reduciría el costo unitario en varios órdenes de magnitud y permitiría clasificación en tiempo real durante la conversación, que es justamente lo que el copiloto necesita.
3. Anotación humana y medición de acuerdo. Es la pieza pendiente más barata y la de mayor retorno. Anotar manualmente las sesenta conversaciones ya muestreadas y calcular el coeficiente kappa de Cohen convertiría todas las etiquetas actuales, hoy respaldadas solo por controles internos de coherencia, en variables con una tasa de error conocida.
4. Modelado predictivo con atribución. Un modelo de propensión al acuerdo, con explicación mediante valores SHAP, permitiría cuantificar la contribución marginal de cada oferta y cada argumento controlando por el motivo declarado. Requiere previamente resolver el problema de volumen: con 78 acuerdos verificados, las celdas por combinación son demasiado pequeñas.
5. Inferencia causal observacional. El emparejamiento por puntaje de propensión o los estimadores doblemente robustos permitirían aproximar el efecto de una oferta sobre la probabilidad de acuerdo, controlando el sesgo de selección que introduce el criterio del asesor. Sigue siendo una aproximación: la asignación no es aleatoria y hay confusores no observados, empezando por la disposición previa del cliente.
6. Minería de procesos sobre la secuencia conversacional. Modelar la conversación como una secuencia de estados y estimar las transiciones mediante cadenas de Markov permitiría identificar en qué punto exacto se pierden las conversaciones y qué secuencias de guion anteceden a un acuerdo. Es especialmente pertinente aquí, donde el 20,8 % de las conversaciones repite un mismo mensaje tres o más veces.
7. Experimento controlado de discursos. Es la única metodología que responde causalmente la pregunta sobre qué argumentos funcionan mejor. Asignar aleatoriamente variantes de guion a asesores comparables durante un periodo definido produce evidencia que ninguna técnica observacional puede igualar. Debería plantearse como la continuación natural del despliegue supervisado descrito en la fase 5.

8. Limitaciones declaradas

Una propuesta que no enumera lo que no sabe está vendiendo algo. Las que siguen no son matices menores: condicionan el alcance de todo lo anterior y deberían acompañar cualquier presentación de estos resultados.

- No existe corpus documental. Ninguna política, manual, guion oficial ni normativa está presente en el dataset. El corpus de conocimiento del prototipo es reconstruido a partir de fragmentos citados por los asesores y constituye un supuesto, no un insumo verificado.
- Los datos son sintéticos. No se conoce el procedimiento de generación ni su fidelidad respecto de la operación real, de modo que los patrones de fricción observados podrían ser artefactos.
- El corpus está truncado en veinte mensajes como mínimo por conversación. Las interacciones cortas, que en una operación real son mayoría, no están representadas y nada de lo concluido les es extrapolable.
- No hay eje temporal. Sin marca de tiempo por mensaje no existen tiempos de respuesta, duración de la conversación ni estacionalidad, y cualquier indicador operativo basado en tiempo queda fuera de alcance.
- No hay identificador de asesor. La dispersión entre asesores, que es la medida natural de estandarización, solo será medible en producción cuando el sistema registre ese dato.
- La anonimización destruyó la información numérica. Montos, saldos y días de mora fueron reemplazados por marcadores, de modo que ningún componente puede razonar sobre cifras reales del cliente.
- Las etiquetas generadas carecen de tasa de error medida. Los controles aplicados son de coherencia interna: detectan contradicciones, no aciertos. En particular, la cifra de acuerdos de pago verificados es una cota superior, porque la verificación comprueba el rol del emisor de la cita pero no que la frase contenga un compromiso con fecha.
- No se han medido embeddings en este proyecto. No hay índice vectorial construido ni latencia ni costo estimados empíricamente para esa capa.

9. Conclusión

La estandarización de respuestas no es un problema de redacción, sino de acceso a la política correcta en el momento correcto. El corpus muestra una operación que ya estandarizó lo fácil, el trámite, y dejó a criterio individual lo difícil, la negociación. Un sistema RAG con intervención

humana obligatoria ataca exactamente ese hueco, y lo hace de un modo auditable: cada sugerencia queda ligada al documento que la respalda, y cada documento a su versión y a su responsable.

La condición de éxito, sin embargo, no es técnica. Es documental. Un sistema de recuperación no puede recuperar lo que no existe, y hoy el manual de políticas de esta operación vive en fragmentos dentro de las conversaciones de sus propios asesores. Constituirlo como documento versionado es el primer paso y probablemente el más valioso, porque ordena la operación con independencia de que el sistema llegue a construirse.

Referencias

- Congreso de la República de Colombia. (2012). Ley 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587.
- Congreso de la República de Colombia. (2021). Ley 2157 de 2021, por medio de la cual se modifica y adiciona la Ley 1266 de 2008 y se dictan disposiciones generales del hábeas data. Diario Oficial No. 51.812.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37-46.
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated evaluation of retrieval augmented generation. *arXiv:2309.15217*.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv:2312.10997*.
- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*.
- Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. (2020). Dense passage retrieval for open-domain question answering. En *Proceedings of EMNLP 2020* (pp. 6769-6781).
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for

- knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- Nogueira, R., & Cho, K. (2019). Passage re-ranking with BERT. *arXiv:1901.04085*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En *Proceedings of EMNLP-IJCNLP 2019* (pp. 3982-3992).
- Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333-389.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41-55.